PROJET DATA ANALYTICS

MCU — Analyse des performances commerciales et critiques

Analyse des films du Marvel Cinematic Universe — Phases 1 à 5

Période analysée : 2008–2024

Lumu Bamana Manassé — Data Analyst

MediJr

GitHub : MediJr — https://github.com/MediJr

Projet**Data Analytics** Période**2008–2024**

Périmètre**Phases 1 à 5** Date**septembre 2026**

Table des matières

1 Synthèse exécutive **3**

1.1 Contexte . . . 3

1.2 Principaux résultats . . . 3

2 Objectifs de l'analyse **3**

3 Données et périmètre **4**

3.1 Source des données . . . 4

3.2 Principales variables . . . 4

4 Préparation et qualité des données **5**

4.1 Profilage initial . . . 5

4.2 Contrôles de cohérence . . . 5

4.3 Nettoyage . . . 5

5 Méthodologie et architecture analytique **5**

6 Analyse des résultats **6**

6.1 Vue globale du catalogue . . . 6

6.2 Performance commerciale par phase . . . 7

6.3 Films générant les plus importants box-offices . . . 7

6.4 Évolution du box-office dans le temps . . . 8

6.5 Rentabilité et retour sur investissement . . . 8

6.6 Relation entre budget et box-office . . . 10

6.7 Films présentant les ROI les plus élevés . . . 10

6.8 Profit par phase . . . 11

6.9 Performance critique . . . 11

6.10 Réception critique et box-office . . . 12

7 Conclusions **13**

8 Recommandations **13**

8.1 Suivre conjointement performance commerciale et rentabilité . . . 14

8.2 Comparer systématiquement les performances entre phases . . . 14

8.3 Examiner les facteurs associés à la performance commerciale . . . 14

8.4 Porter une attention particulière aux performances des phases récentes . . . 14

8.5 Mettre en place un suivi régulier des indicateurs . . . 15

9 Limites de l'analyse **15**

9.1 Taille du dataset 15

9.2 Définition du profit 15

9.3 Corrélation et causalité 15

9.4 Variables non disponibles 16

10 Outil de restitution **16**

11 Conclusion finale **16**

12 Annexes **17**

12.1 Annexe A — Liste des visualisations 17

12.2 Annexe B — Fichiers du projet 17

1 Synthèse exécutive

1.1 Contexte

L'objectif de cette analyse est d'étudier les performances commerciales et critiques des films du Marvel Cinematic Universe (MCU), afin de mieux comprendre les tendances observées au sein du catalogue et les facteurs associés aux performances des films.

L'analyse porte sur 34 films couvrant les Phases 1 à 5 du MCU, avec des informations relatives aux dates de sortie, budgets de production, recettes au box-office, bénéfices calculés, retour sur investissement (ROI) ainsi qu'aux évaluations critiques et spectateurs.

1.2 Principaux résultats

Sur l'ensemble du dataset, les films représentent un budget de production cumulé de 6 947 millions de dollars et un box-office mondial cumulé de 31 129 millions de dollars.

Le bénéfice calculé selon la définition retenue dans le dataset, soit :

$$\textbf{Profit} = \textbf{Box-office mondial} - \textbf{Budget de production}$$

atteint 24 182 millions de dollars.

La note IMDb moyenne du catalogue est de 7,26/10.

L'analyse par phase met en évidence des différences importantes. La Phase 3 présente le box-office moyen, le profit moyen et le ROI global les plus élevés dans le dataset étudié. À l'inverse, les indicateurs financiers moyens observés en Phase 5 sont plus faibles que ceux des phases précédentes.

L'analyse des relations entre variables montre également une association positive entre le budget de production et le box-office mondial. Une association positive est également observée entre la note IMDb et le box-office mondial.

Ces relations doivent toutefois être interprétées comme des associations statistiques et non comme des relations de causalité.

2 Objectifs de l'analyse

Ce projet est un projet personnel. Pour structurer l'analyse, il s'appuie sur le brief métier fictif suivant, rédigé comme cadre de travail (il ne s'agit pas d'une mission réalisée pour un client) :

> « Nous souhaitons analyser les performances commerciales et critiques des films du Marvel Cinematic Universe afin de mieux comprendre les facteurs associés au succès d'un film.
>
> Nous voulons notamment comparer les performances entre les différentes phases du MCU, étudier la relation entre les investissements et les recettes, analyser la rentabilité des films et comparer leurs performances critiques.
>
> À partir de cette analyse, nous souhaitons obtenir des indicateurs et des visualisations permettant à la direction de mieux comprendre les tendances de performance du catalogue. »

À partir de ce besoin, plusieurs axes d'analyse ont été retenus :

— mesurer la performance commerciale ;
— comparer les différentes phases du MCU ;
— analyser la relation entre investissement et recettes ;
— mesurer la rentabilité ;
— comparer les performances critiques ;
— rechercher des facteurs associés aux performances commerciales ;
— observer l'évolution des performances dans le temps.

3 Données et périmètre

3.1 Source des données

Le dataset utilisé contient 34 films du MCU couvrant la période 2008–2024 et comprend 20 variables décrivant notamment les informations temporelles, commerciales, financières et critiques des films.

Les principales sources mentionnées dans la documentation du dataset sont :

— IMDb ;
— Box Office Mojo ;
— Rotten Tomatoes ;
— Wikipedia.

3.2 Principales variables

Les variables utilisées dans l'analyse comprennent notamment :

— titre du film ;
— date et année de sortie ;
— phase du MCU ;
— ordre chronologique ;
— réalisateur ;
— acteur principal ;
— durée ;
— budget de production ;
— box-office mondial ;
— box-office domestique ;
— profit ;
— ROI ;
— part du box-office domestique ;
— note IMDb ;
— score Rotten Tomatoes ;
— score Metacritic.

Le dataset définit le profit comme la différence entre le box-office mondial et le budget de production, tandis que le ROI correspond au rendement calculé à partir du profit et du budget de production.

4 Préparation et qualité des données

4.1 Profilage initial

Un profilage technique du dataset a été réalisé avant l'analyse.

Les contrôles ont permis de confirmer :

— 34 lignes et 20 colonnes ;
— aucune valeur manquante ;
— aucun doublon ;
— 34 identifiants de films uniques ;
— aucune incohérence entre phase et `phase_number` ;
— aucune incohérence entre `release_date` et `release_year` ;
— aucune valeur critique hors des intervalles attendus ;
— aucune durée négative.

4.2 Contrôles de cohérence

Des contrôles supplémentaires ont été effectués sur les variables calculées.

Les valeurs de :

— `profit_millions` ;
— `domestic_percentage` ;
— `roi_percentage`

ont été comparées à leurs formules de calcul respectives.

Aucune incohérence n'a été détectée.

4.3 Nettoyage

La principale correction identifiée concernait le type de données de `release_date`, initialement stocké comme texte.

La colonne a été convertie en véritable type date avant l'export du dataset nettoyé.

Le fichier nettoyé a ensuite été utilisé pour la modélisation et l'analyse dans Power BI.

Conclusion sur la qualité : les contrôles réalisés indiquent que le dataset est cohérent et exploitable pour l'analyse retenue, avec une correction de typage concernant la date de sortie.

5 Méthodologie et architecture analytique

L'analyse a été réalisée en plusieurs étapes :

Étape	Phase	Description
1	Données brutes	Point de départ : données du dataset MCU
2	Profilage	Analyse de la structure, des types, des valeurs manquantes, des doublons et des distributions
3	Contrôle de qualité	Vérification de la validité, de la cohérence et de l'intégrité des données
4	Nettoyage	Correction des types et préparation du fichier exploitable
5	Analyse exploratoire	Exploration des données avec Python/Pandas et identification des principaux résultats
6	Modélisation	Construction du modèle en étoile dans Power BI
7	Indicateurs	Création des mesures analytiques avec DAX
8	Visualisation et analyse	Construction du tableau de bord et interprétation des résultats

La modélisation Power BI repose sur un schéma en étoile comprenant :

— `Fact_Movie` ;
— `Dim_Movie` ;
— `Dim_Phase` ;
— `Dim_Date`.

La granularité de la table de faits est :

1 film = 1 ligne dans `Fact_Movie`.

Cette structure permet notamment d'analyser les performances selon le film, la phase et la période de sortie.

6 Analyse des résultats

6.1 Vue globale du catalogue

Les principaux indicateurs du catalogue sont les suivants :

Indicateur	Résultat
Nombre de films	34
Budget total	6 947 M$
Box-office mondial total	31 129 M$
Profit calculé total	24 182 M$
Box-office mondial moyen	915,56 M$
Budget moyen	204,32 M$
ROI moyen par film	339,58 %
Note IMDb moyenne	7,26/10
Rotten Tomatoes moyen	80,71 %
Metacritic moyen	66/100

La capture du dashboard ci-dessous a été réalisée avec la Phase 3 sélectionnée : les cartes d'indicateurs affichent donc les valeurs de cette phase (11 films, 13 500 M$ de box-office mondial, 11 179 M$ de profit, note IMDb moyenne de 7,59) et non celles de l'ensemble du catalogue, qui figurent dans le tableau ci-dessus.

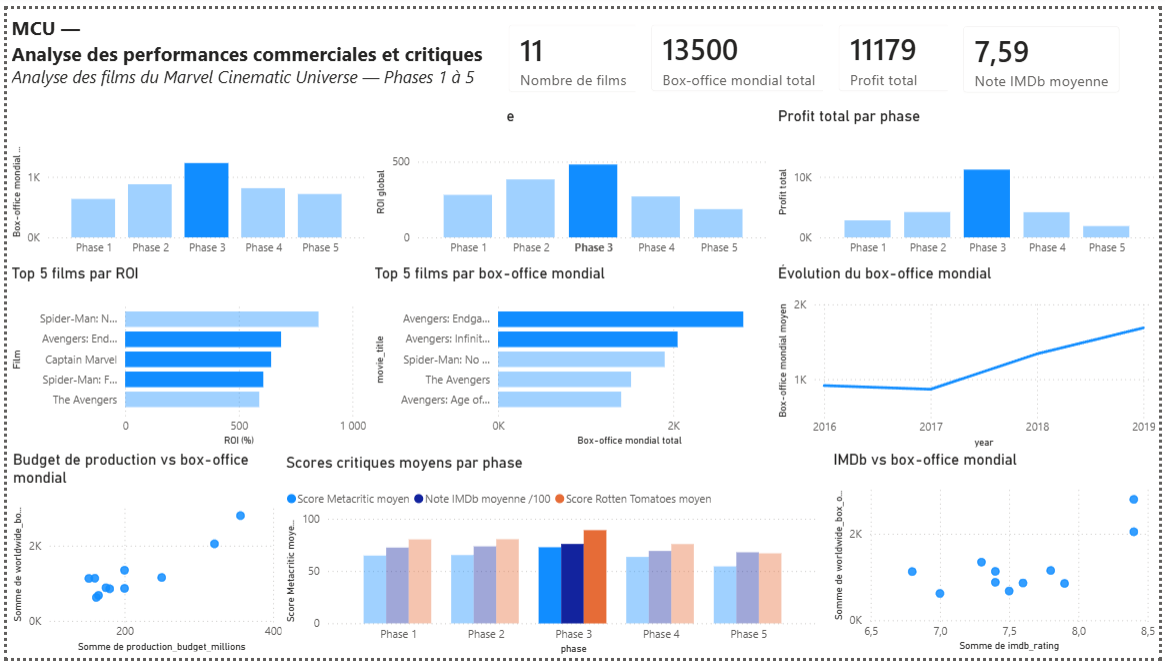


FIGURE 1 – Dashboard Power BI MCU (Phase 3 sélectionnée)

6.2 Performance commerciale par phase

Le box-office mondial moyen varie sensiblement selon les phases.

Les moyennes observées sont :

Phase	Box-office mondial moyen
Phase 1	634,83 M$
Phase 2	877,67 M$
Phase 3	1 227,27 M$
Phase 4	812,71 M$
Phase 5	716,25 M$

La Phase 3 présente donc le niveau moyen de box-office mondial le plus élevé dans le périmètre étudié.

6.3 Films générant les plus importants box-offices

Les cinq films ayant généré les plus importants box-offices mondiaux dans le dataset sont :

Film	Box-office mondial
Avengers: Endgame	2 798 M$
Avengers: Infinity War	2 048 M$
Spider-Man: No Way Home	1 902 M$
The Avengers	1 518 M$
Avengers: Age of Ultron	1 405 M$

Ces résultats montrent que certains films contribuent fortement à la performance commerciale globale du catalogue.

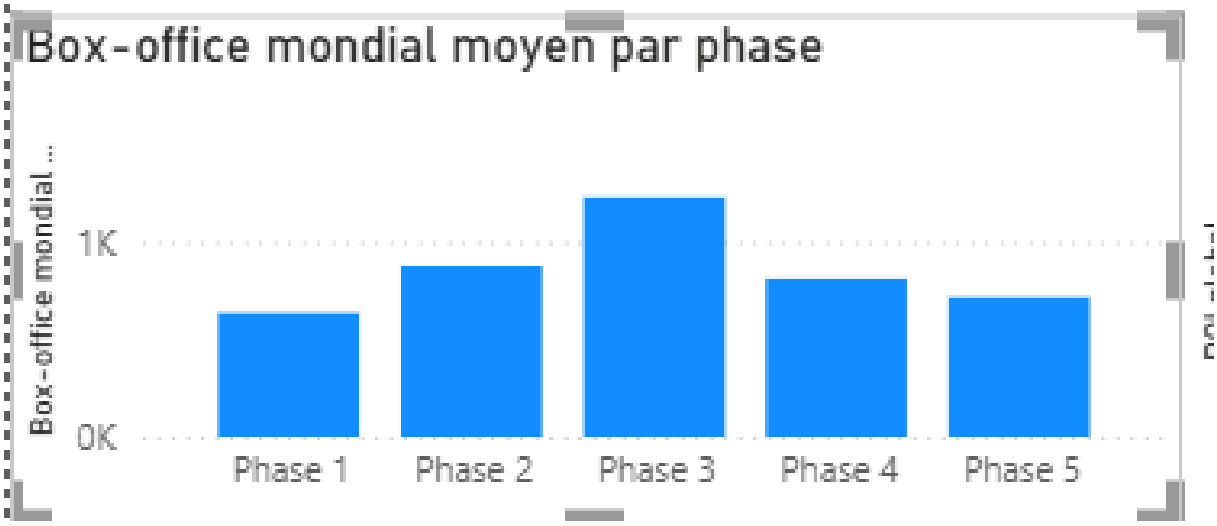


FIGURE 2 – Box-office mondial moyen par phase

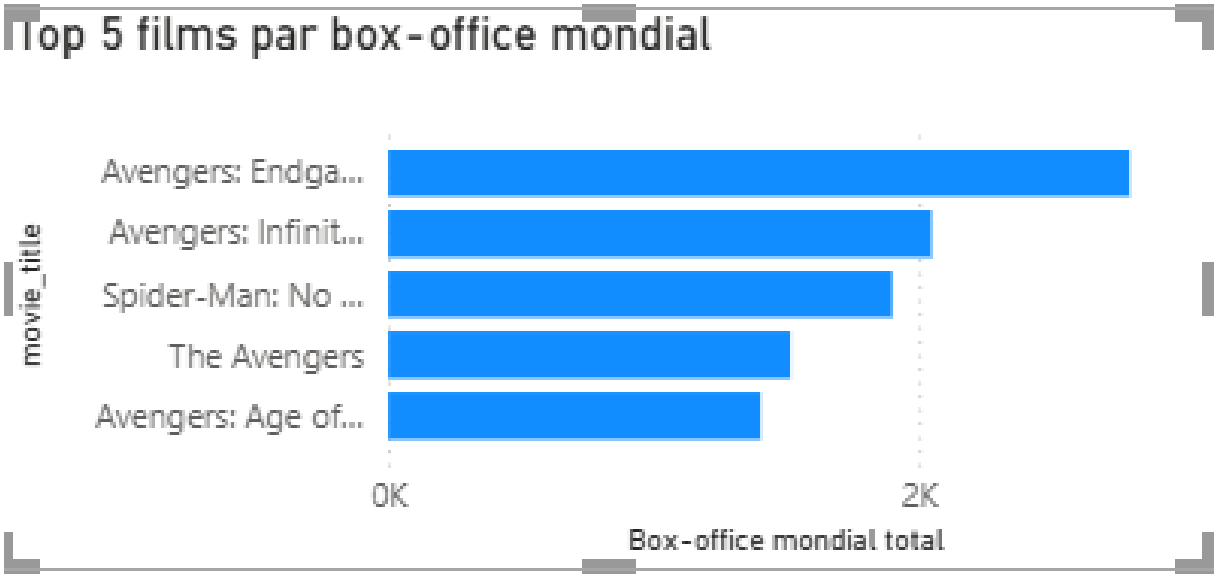


FIGURE 3 – Top 5 films par box-office mondial

6.4 Évolution du box-office dans le temps

L'évolution annuelle fait apparaître des variations importantes de la performance commerciale moyenne au cours de la période étudiée.

Les moyennes annuelles les plus élevées concernent 2019 (1 686 M$), 2012 (1 518 M$), 2018 (1 338,67 M$) et 2024 (1 338 M$). Chaque année ne compte qu'un à quatre films, et aucun film n'est sorti en 2020 : ces moyennes annuelles dépendent donc fortement de quelques titres.

L'évolution n'est donc pas linéaire : plusieurs périodes de progression et de baisse sont observées.

6.5 Rentabilité et retour sur investissement

Le ROI global a été calculé selon la formule :

$$\textbf{ROI global} = \textbf{Profit total} \;/\; \textbf{Budget total} \times \textbf{100}$$

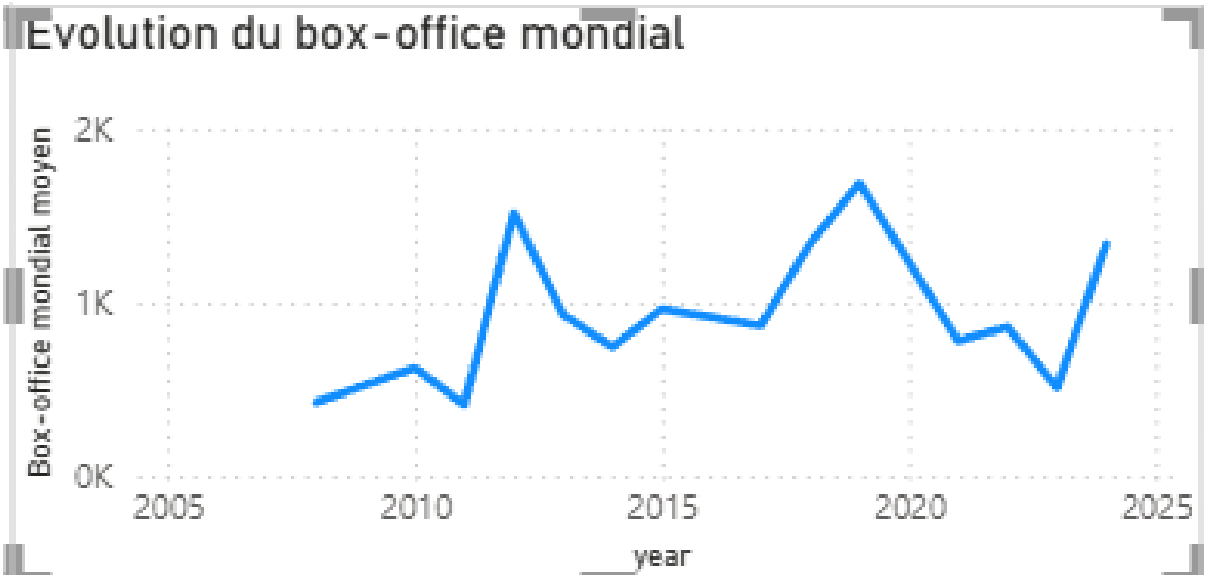


FIGURE 4 – Évolution du box-office mondial

Cette méthode permet de mesurer l'efficacité globale des investissements plutôt que de calculer simplement la moyenne des ROI individuels.

Les résultats par phase sont :

Phase	**ROI global**
Phase 1	280,90 %
Phase 2	383,12 %
Phase 3	481,65 %
Phase 4	270,38 %
Phase 5	186,50 %

Sur l'ensemble du catalogue, le ROI global vaut 348,09 % (24 182 / 6 947), contre 339,58 % pour la moyenne des ROI individuels.

La Phase 3 présente ainsi le ROI global le plus élevé parmi les cinq phases étudiées.

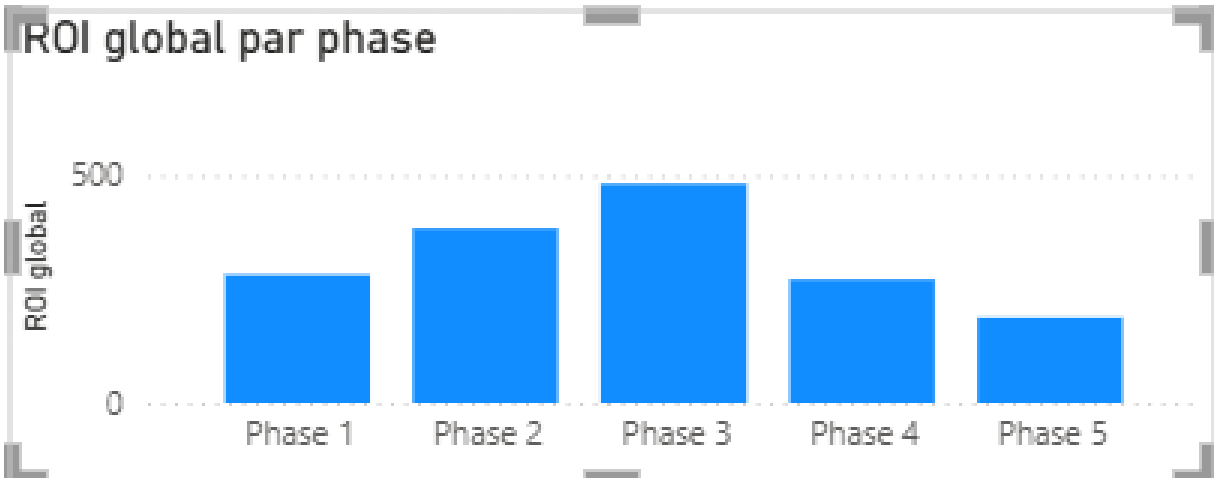


FIGURE 5 – ROI global par phase

6.6 Relation entre budget et box-office

L'analyse du budget de production et du box-office mondial montre une corrélation positive d'environ 0,63 dans le dataset.

Cela indique qu'au sein des données étudiées, les films bénéficiant de budgets plus élevés tendent également à être associés à des box-offices plus élevés.

Cependant, cette relation ne permet pas d'établir que l'augmentation du budget provoque automatiquement une augmentation du box-office.

D'autres facteurs peuvent intervenir et ne sont pas directement mesurés dans le dataset.

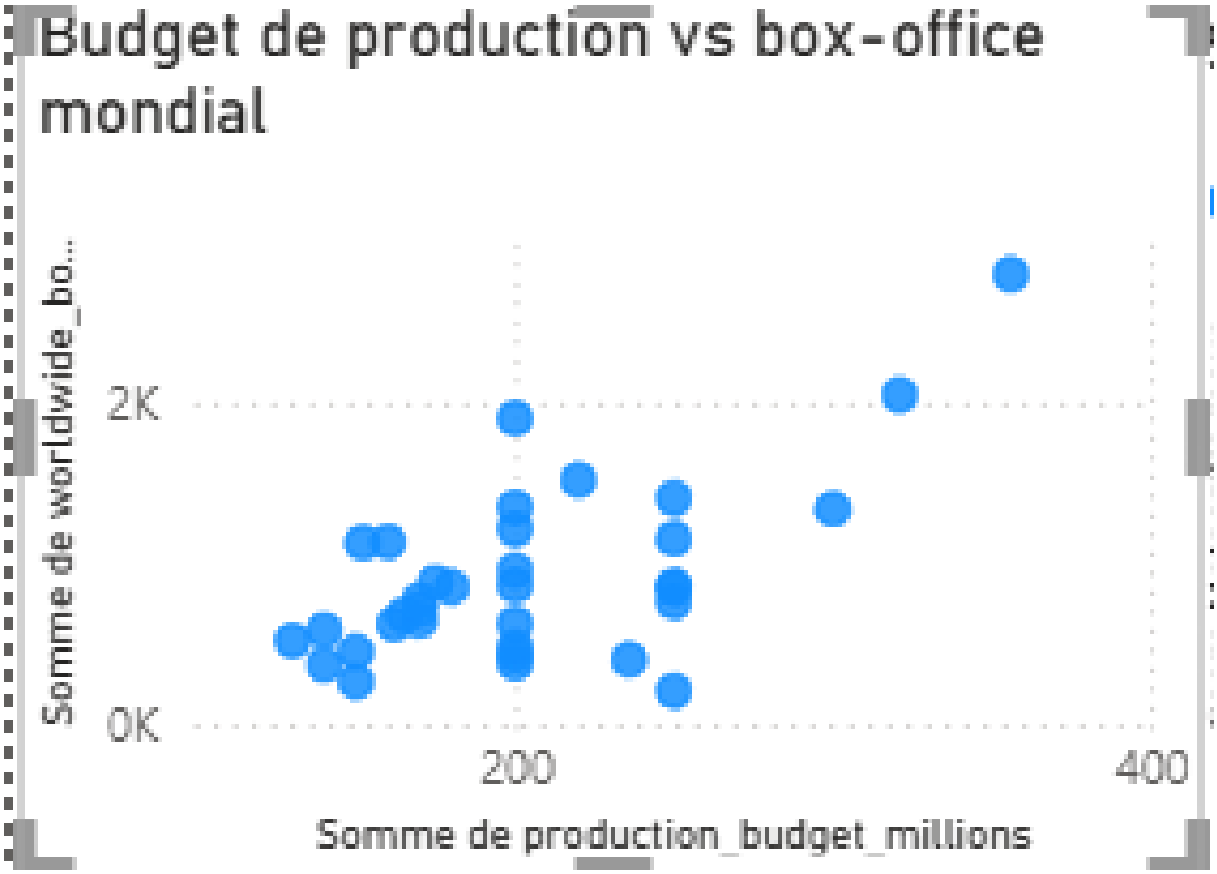


FIGURE 6 – Budget de production vs box-office mondial

6.7 Films présentant les ROI les plus élevés

L'analyse du ROI individuel permet d'identifier les films ayant généré le rendement le plus élevé par rapport à leur budget de production.

Les principaux résultats comprennent notamment :

— Spider-Man: No Way Home ;
— Avengers: Endgame ;
— Captain Marvel ;
— Spider-Man: Far From Home ;
— The Avengers.

Le ROI constitue ici un indicateur complémentaire au box-office : un film générant moins de

recettes peut présenter un rendement supérieur s'il a été produit avec un investissement relativement faible.

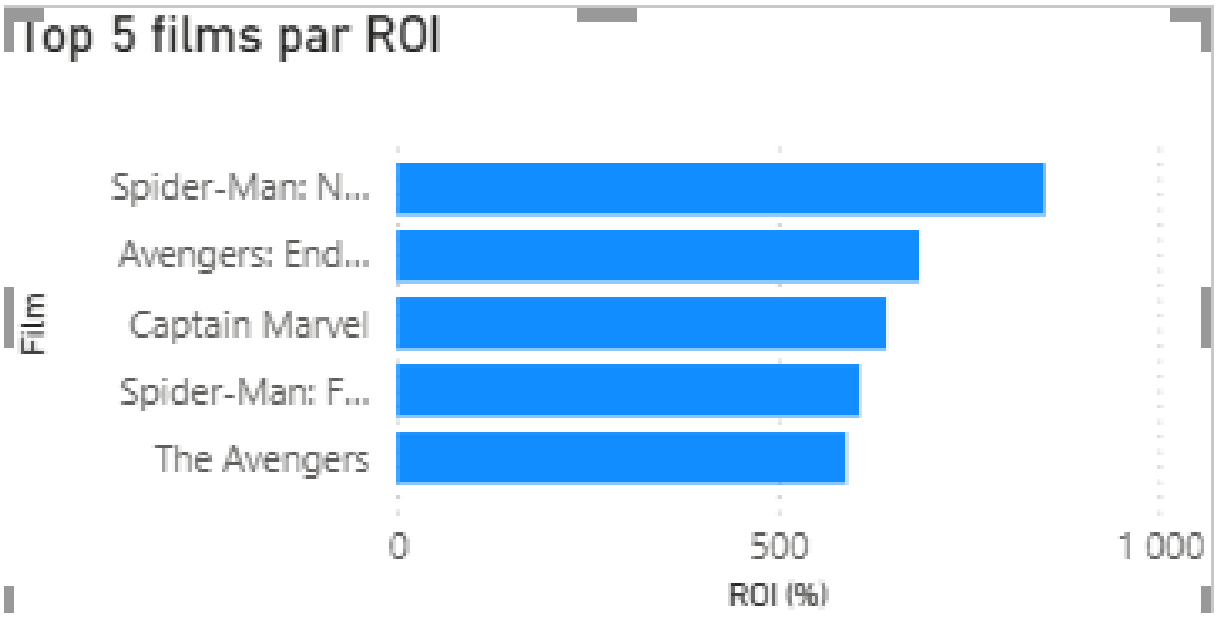


FIGURE 7 – Top 5 films par ROI

6.8 Profit par phase

Le profit total varie également fortement entre les phases.

Les résultats montrent une contribution particulièrement importante de la Phase 3, qui génère le profit total le plus élevé dans le dataset.

Cette observation est cohérente avec son niveau élevé de box-office et de ROI global.

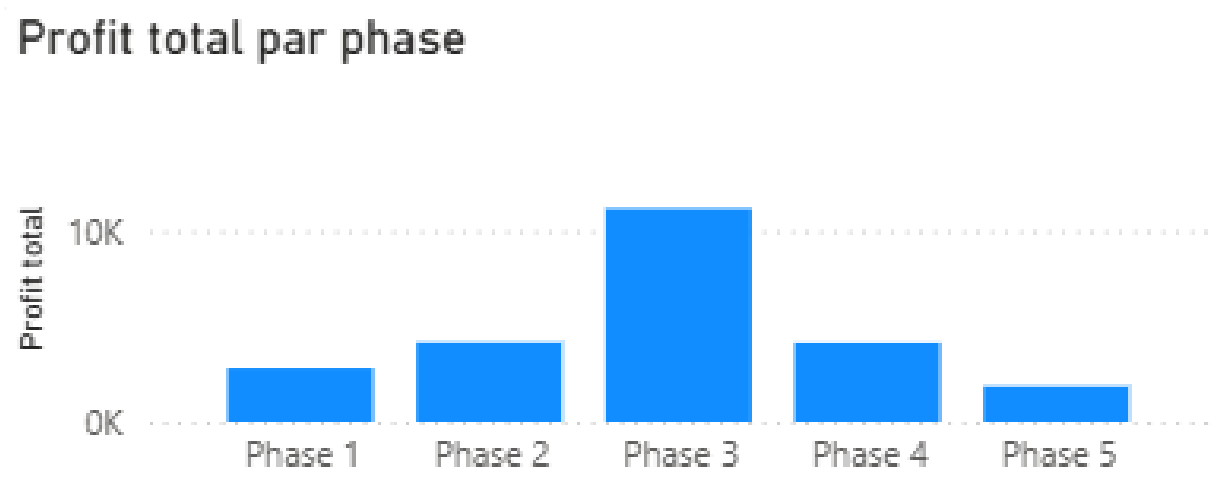


FIGURE 8 – Profit total par phase

6.9 Performance critique

Trois indicateurs critiques ont été comparés :

— IMDb ;
— Rotten Tomatoes ;
— Metacritic.

Pour faciliter la comparaison visuelle, la note IMDb a été convertie sur une échelle de 100 pour cette visualisation uniquement.

Les moyennes observées par phase sont :

Phase	IMDb /100	Rotten Tomatoes	Metacritic
Phase 1	72,5	80,33	64,83
Phase 2	73,7	80,50	65,33
Phase 3	75,9	89,09	72,73
Phase 4	69,3	75,86	63,57
Phase 5	68,0	67,00	54,50

Dans le dataset étudié, la Phase 3 présente les moyennes critiques les plus élevées pour les trois indicateurs.

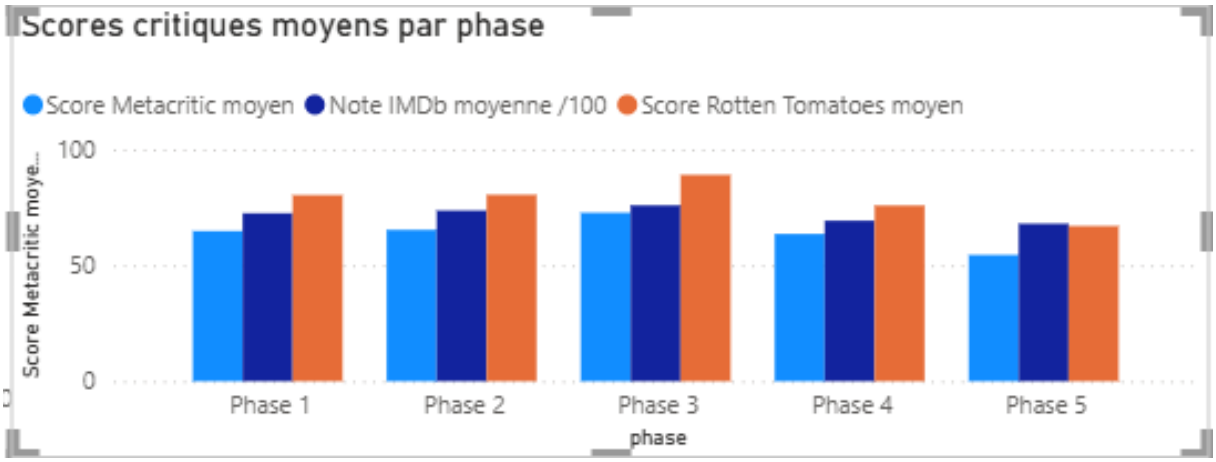


FIGURE 9 – Scores critiques moyens par phase

6.10 Réception critique et box-office

L'analyse exploratoire montre une corrélation d'environ 0,66 entre la note IMDb et le box-office mondial.

Cette relation est plus élevée que celles observées avec Rotten Tomatoes et Metacritic :

— IMDb ↔ Box-office : 0,66
— Rotten Tomatoes ↔ Box-office : 0,44
— Metacritic ↔ Box-office : 0,42

Dans ce dataset, la note IMDb présente donc l'association statistique la plus forte avec le box-office parmi les trois indicateurs critiques étudiés.

Il est toutefois important de rappeler qu'une corrélation ne démontre pas une relation de causalité.

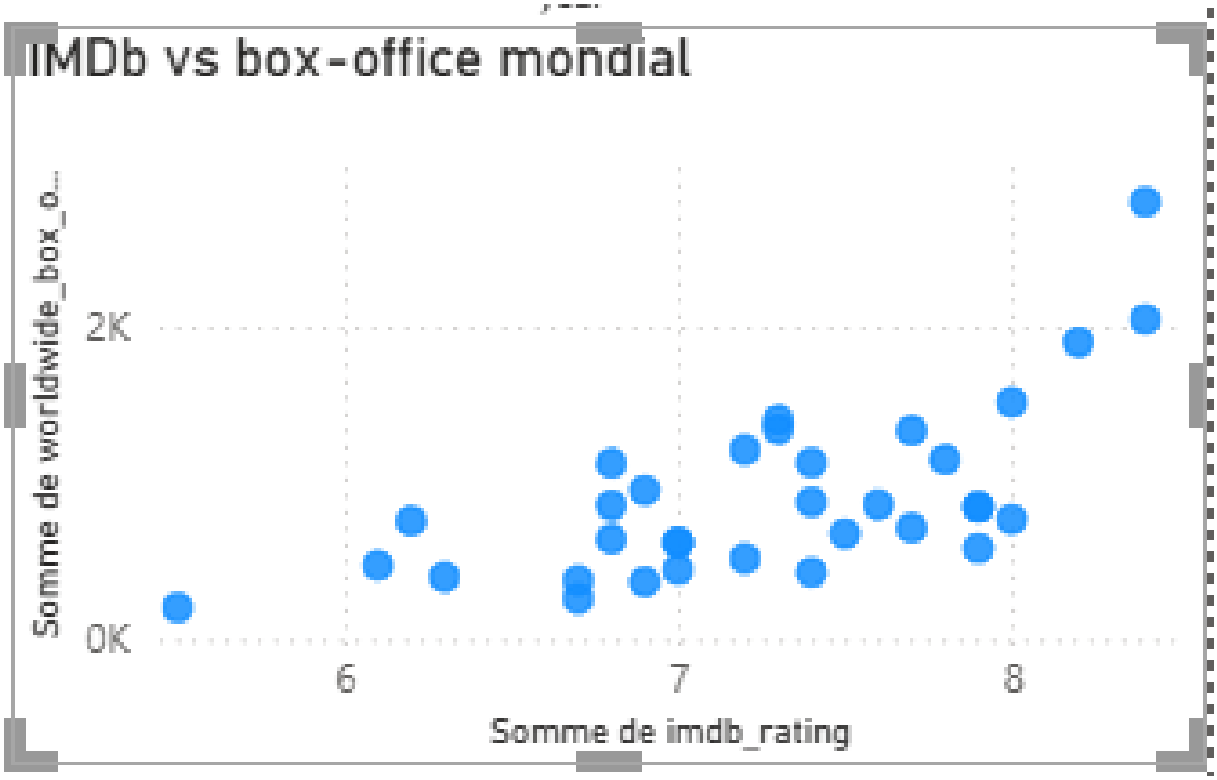


FIGURE 10 – IMDb vs box-office mondial

7 Conclusions

L'analyse des 34 films étudiés met en évidence plusieurs enseignements.

Premièrement, les performances commerciales et financières varient fortement selon les phases du MCU. La Phase 3 présente les niveaux moyens les plus élevés de box-office ainsi que le ROI global et le profit total les plus importants dans le périmètre étudié.

Deuxièmement, quelques films représentent une part importante des performances commerciales du catalogue. Avengers: Endgame, Avengers: Infinity War et Spider-Man: No Way Home figurent parmi les films générant les plus importants box-offices mondiaux.

Troisièmement, l'analyse met en évidence une association positive entre le budget de production et le box-office mondial. Cependant, le budget ne suffit pas à expliquer à lui seul les performances commerciales.

Quatrièmement, la réception critique présente également une association positive avec le box-office, particulièrement dans le cas de la note IMDb. Cette observation suggère qu'il peut être pertinent d'étudier conjointement les indicateurs commerciaux et critiques.

Enfin, les résultats montrent une diminution des indicateurs moyens de performance commerciale, de rentabilité et de réception critique entre certaines phases récentes et la Phase 3. Cette évolution constitue un point d'attention qui mériterait une analyse plus approfondie.

8 Recommandations

Les recommandations suivantes sont directement fondées sur les résultats observés.

8.1 Suivre conjointement performance commerciale et rentabilité

Le box-office seul ne permet pas de mesurer l'efficacité d'un investissement.

Il est donc recommandé de suivre simultanément :

— le budget ;
— le box-office ;
— le profit ;
— le ROI.

Cette approche permet de distinguer les films générant beaucoup de recettes de ceux qui transforment efficacement leur investissement en bénéfices.

8.2 Comparer systématiquement les performances entre phases

Les écarts observés entre les phases montrent l'intérêt d'un suivi périodique des indicateurs par période.

Un tableau de bord permettant de comparer chaque nouvelle phase aux phases précédentes pourrait faciliter l'identification rapide des changements de performance.

8.3 Examiner les facteurs associés à la performance commerciale

La relation observée entre budget et box-office ainsi que celle observée entre IMDb et box-office justifient une analyse complémentaire des facteurs associés au succès commercial.

Une analyse future pourrait intégrer d'autres variables telles que :

— genre ;
— personnage principal ;
— réalisateur ;
— franchise ;
— calendrier de sortie ;
— marketing ;
— concurrence au moment de la sortie ;
— contexte économique ;
— durée d'exploitation.

Cela permettrait d'aller au-delà des variables actuellement disponibles.

8.4 Porter une attention particulière aux performances des phases récentes

Les indicateurs moyens observés pour les phases 4 et 5 sont inférieurs à ceux de la Phase 3 sur plusieurs dimensions.

Il serait donc pertinent de réaliser une analyse approfondie des films concernés afin d'identifier les caractéristiques communes aux performances les plus faibles et aux performances les plus élevées.

Cette analyse devrait distinguer les tendances générales des cas individuels afin d'éviter de tirer des conclusions à partir d'un nombre limité de films.

8.5 Mettre en place un suivi régulier des indicateurs

Le dashboard Power BI peut servir de base à un système de suivi des performances.

Les indicateurs principaux à suivre seraient notamment :

Performance commerciale

— box-office mondial ;
— box-office moyen ;
— évolution temporelle.

Rentabilité

— profit ;
— ROI ;
— budget.

Performance critique

— IMDb ;
— Rotten Tomatoes ;
— Metacritic.

L'utilisation régulière de ces indicateurs permettrait de suivre l'évolution du catalogue et de comparer les nouvelles productions aux performances historiques.

9 Limites de l'analyse

Plusieurs limites doivent être prises en compte lors de l'interprétation des résultats.

9.1 Taille du dataset

L'analyse porte sur seulement 34 films. Les résultats doivent donc être interprétés dans le périmètre de ce dataset et ne doivent pas être généralisés automatiquement à l'ensemble de l'industrie cinématographique.

9.2 Définition du profit

Le profit utilisé dans cette analyse correspond à :

Box-office mondial − budget de production

Il s'agit donc d'un indicateur calculé, et non nécessairement du bénéfice comptable réel d'un studio.

Les coûts de marketing, distribution, taxes, commissions et autres dépenses ne sont pas intégrés dans cette formule.

9.3 Corrélation et causalité

Les corrélations observées permettent d'identifier des associations entre variables, mais elles ne permettent pas d'établir une causalité.

Par exemple, une corrélation positive entre budget et box-office ne signifie pas nécessairement qu'un budget plus élevé entraîne directement davantage de recettes.

9.4 Variables non disponibles

Certains facteurs susceptibles d'influencer les performances commerciales ne figurent pas dans le dataset.

Les résultats doivent donc être considérés comme une analyse descriptive et exploratoire du catalogue étudié.

10 Outil de restitution

Un dashboard Power BI interactif a été développé afin de permettre l'exploration des résultats.

Le dashboard regroupe :

— les KPI principaux ;
— la performance par phase ;
— les films les plus performants ;
— l'évolution temporelle ;
— le ROI ;
— le profit ;
— les scores critiques ;
— la relation budget/box-office ;
— la relation IMDb/box-office.

Les visualisations ont été sélectionnées à partir des besoins métier afin d'éviter de multiplier les graphiques sans valeur analytique supplémentaire. La sélection finale comprend 9 visualisations principales couvrant les dimensions commerciales, financières, critiques et temporelles du problème.

11 Conclusion finale

Cette analyse a permis de construire une chaîne complète allant de la compréhension du besoin métier jusqu'à la restitution interactive des résultats.

Le projet a couvert :

— le cadrage du problème ;
— l'inventaire et la compréhension des données ;
— le profilage ;
— le contrôle de qualité ;
— le nettoyage ;
— l'analyse exploratoire avec Python ;
— la modélisation dimensionnelle ;
— la création de mesures DAX ;
— la conception de visualisations adaptées aux questions métier ;
— la réalisation d'un dashboard Power BI interactif.

Les résultats permettent de mieux comprendre les différences de performance entre les phases du MCU, la relation entre investissements et recettes, la rentabilité des films et les associations

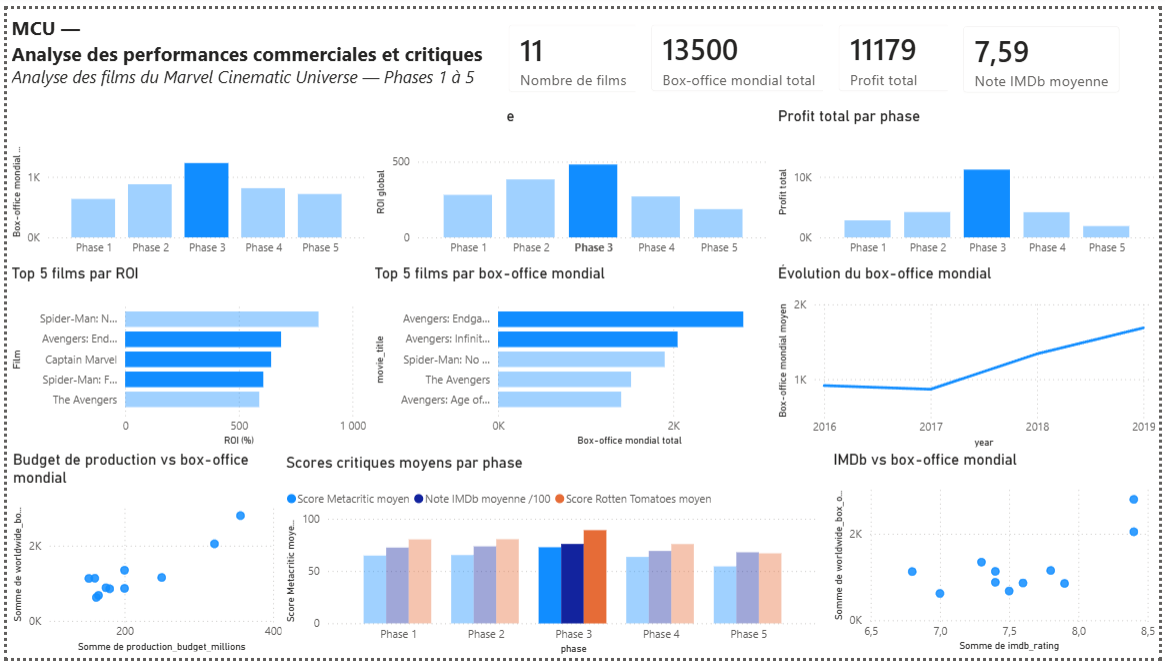


FIGURE 11 – Tableau de bord Power BI final (Phase 3 sélectionnée)

entre réception critique et performance commerciale.

Le dashboard constitue ainsi un outil de synthèse permettant d'explorer les performances du catalogue, tandis que le présent rapport fournit le contexte, les méthodes, les principaux résultats, les conclusions et les pistes d'analyse complémentaires.

12 Annexes

12.1 Annexe A — Liste des visualisations

N°	Visualisation
1	Box-office mondial moyen par phase
2	Top 5 films par box-office mondial
3	Évolution du box-office mondial
4	ROI global par phase
5	Budget de production vs box-office mondial
6	Top 5 films par ROI
7	Profit total par phase
8	Scores critiques moyens par phase
9	IMDb vs box-office mondial

Cette sélection correspond à la conception finale définie pour le dashboard.

12.2 Annexe B — Fichiers du projet

Les principaux fichiers techniques du projet comprennent notamment :

— dataset original ;
— dataset nettoyé ;

— scripts Python de profilage, nettoyage et analyse ;
— modèle Power BI ;
— rapport d'analyse.